

UniFECAF

Marcos Detrano Rodrigues Junior

NEXADESK AI: Seu copiloto inteligente para o conhecimento da empresa

São Paulo

2026

Marcos Detrano Rodrigues Junior

NEXADESK AI: Seu copiloto inteligente para o conhecimento da empresa

Trabalho de conclusão apresentado à disciplina de IA Generativa Aplicada ao
Desenvolvimento da **UniFECAF**.

Orientador(a): Prof.(a) **Patricia Miscolcz**

São Paulo

2026

RESUMO

O presente trabalho descreve o desenvolvimento do NexaDesk AI, um copiloto corporativo baseado em Inteligência Artificial Generativa, concebido para responder, em linguagem natural, dúvidas recorrentes de colaboradores sobre políticas, processos e procedimentos internos de uma organização. O projeto foi construído no contexto da disciplina de IA Generativa Aplicada ao Desenvolvimento e possui dois propósitos complementares: entregar um produto SaaS funcional, com aparência profissional, e demonstrar, de forma transparente, como ferramentas de IA Generativa participaram ativamente de todas as etapas da sua construção. A aplicação foi implementada utilizando React, TypeScript, Vite, TailwindCSS v4 e TanStack Start, adotando uma arquitetura modular composta por uma camada de dados (base de conhecimento simulada), uma camada de agente (responsável pelo retrieval e pela montagem dos prompts) e uma camada de interface conversacional. O agente implementa um fluxo simplificado de Retrieval-Augmented Generation (RAG). Os resultados indicam que a adoção de IA Generativa reduziu significativamente o tempo de entrega do MVP, ampliou a qualidade visual da interface e permitiu produzir documentação técnica detalhada, mantendo a aderência a boas práticas de engenharia de software, governança e segurança aplicáveis a modelos de linguagem.

ABSTRACT

This work describes the development of NexaDesk AI, a corporate copilot powered by Generative Artificial Intelligence, designed to answer, in natural language, recurring employee questions about internal policies, processes, and procedures of an organization. The application was implemented using React, TypeScript, Vite, TailwindCSS v4, and TanStack Start, following a modular architecture composed of a data layer, an agent layer (Retrieval-Augmented Generation pipeline), and a conversational interface. Tools such as Lovable, Claude, ChatGPT, and GitHub Copilot were employed throughout development, and their contributions were documented in terms of time saved, code quality, and influence on architectural decisions.

Sumário

- RESUMO 3
- ABSTRACT 4
- 1. INTRODUÇÃO 6
- 2. OBJETIVOS 7
- 3. FUNDAMENTAÇÃO TEÓRICA..... 7
- 4. DESENVOLVIMENTO DO PROJETO..... 8
- 5. FERRAMENTAS UTILIZADAS 9
- 6. COMO A IA AUXILIOU O DESENVOLVIMENTO 9
- 7. FUNCIONALIDADES DO SISTEMA..... 9
- 8. BENEFÍCIOS OBTIDOS..... 10
- 9. LIMITAÇÕES ENCONTRADAS 10
- 10. ASPECTOS ÉTICOS E GOVERNANÇA DA IA..... 10
- 11. TRABALHOS FUTUROS 11
- 12. CONCLUSÃO 12
- 13. REFERÊNCIAS BIBLIOGRÁFICAS 13

1. INTRODUÇÃO

A última década consolidou a transformação digital como vetor estratégico para organizações de todos os portes. Processos antes manuais foram automatizados, sistemas legados migraram para a nuvem e a quantidade de dados produzidos cresceu de forma exponencial. Nesse cenário, a emergência da Inteligência Artificial Generativa representa, segundo diversos autores, uma ruptura comparável à popularização da internet ou à chegada dos smartphones (BROWN et al., 2020; OPENAI, 2023).

A consolidação dos Large Language Models (LLMs), em especial após a publicação da arquitetura Transformer por Vaswani et al. (2017), permitiu que sistemas como GPT, Claude e Gemini executassem com proficiência tarefas linguísticas complexas. A IA Generativa deixou de ser tema acadêmico restrito e passou a integrar a estratégia digital de grandes empresas.

Apesar do avanço tecnológico, o conhecimento corporativo permanece fragmentado, redundante e de difícil acesso. Pesquisas conduzidas pela McKinsey (2012) já apontavam que profissionais do conhecimento dedicam, em média, 1,8 horas por dia apenas para localizar informações internas. Isso afeta particularmente os processos de onboarding e as áreas de suporte interno.

A pergunta que motiva este trabalho é: como reduzir o atrito entre o colaborador e o conhecimento oficial da empresa, oferecendo respostas confiáveis, em linguagem natural, sem aumentar a carga sobre os times de suporte? A justificativa baseia-se na convergência da maturidade técnica dos LLMs, na demanda corporativa real e no caráter formativo da disciplina de evidenciar como a IA participa da construção de software.

2. OBJETIVOS

O objetivo geral é desenvolver um copiloto corporativo baseado em IA Generativa, denominado NexaDesk AI, capaz de responder em linguagem natural a perguntas sobre políticas, processos e procedimentos de uma empresa fictícia, demonstrando simultaneamente como ferramentas de IA Generativa participam ativamente do processo de engenharia de software.

Os objetivos específicos são:

- Modelar uma base de conhecimento corporativa simulada em TypeScript.
- Implementar um agente de retrieval lexical que selecione os trechos mais relevantes da base.
- Projetar prompts isolados e versionáveis compatíveis com APIs comerciais de LLM.
- Construir uma interface SaaS profissional com tema escuro, chat, base de conhecimento e favoritos.
- Garantir persistência local da sessão, do histórico de conversa e dos favoritos.
- Documentar prompt-a-prompt o uso de IA Generativa durante o desenvolvimento.
- Aplicar boas práticas de governança e segurança alinhadas ao OWASP Top 10 for LLM Applications.
- Deixar a aplicação preparada para integração futura com LLMs comerciais e com o Model Context Protocol (MCP).

3. FUNDAMENTAÇÃO TEÓRICA

A Inteligência Artificial Generativa é uma subárea da IA cujos modelos produzem conteúdo novo a partir de padrões aprendidos em grandes volumes de dados (FOSTER, 2023). Os Large Language Models são redes neurais profundas, tipicamente baseadas na arquitetura Transformer, que produzem comportamentos emergentes como tradução e geração de código.

A engenharia de prompt consiste em projetar instruções textuais que orientem o LLM, mitigando ataques através do isolamento de regras imutáveis no system prompt. O paradigma Retrieval-Augmented Generation (RAG), formalizado por Lewis et al. (2020), combina recuperação de informação e geração textual, oferecendo atualidade, rastreabilidade e redução de alucinações.

O desenvolvimento assistido por IA redefine o ciclo de engenharia de software. Ferramentas como GitHub Copilot, ChatGPT e Claude completam tarefas rapidamente, mas exigem do desenvolvedor uma postura crítica. A segurança dessas aplicações deve seguir diretrizes como as da OWASP, mitigando riscos de injeção de prompt e exposição de dados.

4. DESENVOLVIMENTO DO PROJETO

O projeto foi planejado privilegiando a construção de um MVP funcional ponta a ponta. A arquitetura adota uma separação clara em três camadas: uma UI em React e TypeScript, um agente lógico puro em TS para retrieval e montagem de prompts, e uma camada de resposta que renderiza Markdown com citações.

O frontend foi construído com React 19, Vite 7 e TailwindCSS v4. Para o MVP acadêmico, a aplicação opera sem backend dedicado, utilizando o localStorage para persistência de dados. O banco de dados simulado é um arquivo TypeScript contendo 77 entradas. A função central de mock do LLM foi projetada como um ponto único de substituição, permitindo uma futura troca rápida para chamadas reais à OpenAI ou Anthropic sem quebrar o sistema.

5. FERRAMENTAS UTILIZADAS

- Claude (Anthropic): Utilizado para definição de arquitetura, componentes complexos e redação desta documentação.
- ChatGPT (OpenAI): Utilizado para brainstorming inicial e geração da base de conhecimento simulada.
- GitHub e GitHub Copilot: Versionamento de código e autocomplete inteligente durante o desenvolvimento.
- React e TypeScript: Bibliotecas para interface de usuário e tipagem estática.
- Tailwind CSS: Framework utilizado para a criação do design system e tema escuro.
- Supabase e APIs LLM (OpenAI): Estruturas preparadas em código para futuras integrações de autenticação e chamadas reais.

6. COMO A IA AUXILIOU O DESENVOLVIMENTO

A IA atuou gerando mais de 70% do código inicial, auxiliando em decisões arquiteturais, engenharia de prompt e na resolução de bugs. A documentação acadêmica foi co-escrita em paralelo. Estima-se que o MVP tenha sido entregue em aproximadamente 2 horas de iteração assistida, em contraposição a um esforço tradicional estimado entre 16 a 24 horas. Esse ganho de produtividade ressalta a mudança do paradigma de desenvolvimento para uma lógica de pair programming virtual.

7. FUNCIONALIDADES DO SISTEMA

As funcionalidades do NexaDesk AI incluem um login corporativo fictício, uma interface conversacional de chat (que renderiza Markdown e exibe fontes), um dashboard com métricas, uma base de conhecimento navegável, suporte a favoritar documentos, exportação/cópia de conversas e persistência de sessão e histórico puramente em cache local.

8. BENEFÍCIOS OBTIDOS

O projeto resultou na redução hipotética do tempo de busca de informações corporativas, padronização de respostas baseadas em dados oficiais e alívio do suporte interno. Academicamente, entregou-se uma documentação rica que comprova o domínio técnico na orquestração de IA Generativa para engenharia de software.

9. LIMITAÇÕES ENCONTRADAS

O MVP atual conta com limitações inerentes ao escopo didático: a busca é puramente lexical (o que limita a abrangência semântica), não há conexão dinâmica com um LLM real operando, e a persistência é restrita ao armazenamento local do navegador, sem contar com autenticação real ou coleta de telemetria.

10. ASPECTOS ÉTICOS E GOVERNANÇA DA IA

A aplicação foi projetada em consonância com princípios estabelecidos pelo NIST AI RMF e pela OWASP. Garante-se a transparência (exibindo a fonte das respostas), a mitigação de alucinações (com fallbacks rígidos no system prompt) e a proteção de dados (utilizando base fictícia sem dados pessoais sensíveis). Não há ferramentas que realizem alterações diretas nos sistemas, garantindo a supervisão humana obrigatória.

11. TRABALHOS FUTUROS

Planeja-se para o futuro:

- Conexão com provedores reais de LLM via Edge Functions.
- Substituição da busca lexical por embeddings e bancos vetoriais (pgvector).
- Implementação de persistência com banco de dados gerenciado.
- Integração do Model Context Protocol (MCP) e Single Sign-On (SSO).
- Criação de um painel administrativo.

12. CONCLUSÃO

O NexaDesk AI demonstrou que é possível construir um copiloto corporativo viável e com alto padrão visual através do uso intenso de IA Generativa. O trabalho atende ao propósito da disciplina de IA Generativa Aplicada ao Desenvolvimento, evidenciando como os modelos não substituem o desenvolvedor, mas exigem dele habilidades novas, como engenharia de prompt, pensamento crítico e gestão de arquitetura.

13. REFERÊNCIAS BIBLIOGRÁFICAS

ANTHROPIC. INTRODUCING THE MODEL CONTEXT PROTOCOL. SÃO FRANCISCO: ANTHROPIC, 2024. DISPONÍVEL EM: [HTTPS://WWW.ANTHROPIC.COM/NEWS/MODEL-CONTEXT-PROTOCOL](https://www.anthropic.com/news/model-context-protocol). ACESSO EM: 15 JUN. 2026.

ANTHROPIC. CLAUDE DOCUMENTATION. SÃO FRANCISCO: ANTHROPIC, 2025. DISPONÍVEL EM: [HTTPS://DOCS.ANTHROPIC.COM](https://docs.anthropic.com). ACESSO EM: 15 JUN. 2026.

BROWN, T. ET AL. LANGUAGE MODELS ARE FEW-SHOT LEARNERS. IN: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33, 2020. PROCEEDINGS... NEURIPS, 2020.

FOSTER, D. GENERATIVE DEEP LEARNING. 2. ED. SEBASTOPOL: O'REILLY MEDIA, 2023.

GITHUB. RESEARCH: QUANTIFYING GITHUB COPILOT'S IMPACT ON DEVELOPER PRODUCTIVITY AND HAPPINESS. GITHUB BLOG, 2022. DISPONÍVEL EM: [HTTPS://GITHUB.BLOG/2022-09-07-RESEARCH-QUANTIFYING-GITHUB-COPILOTS-IMPACT-ON-DEVELOPER-PRODUCTIVITY-AND-HAPPINESS/](https://github.blog/2022-09-07-research-quantifying-github-copilots-impact-on-developer-productivity-and-happiness/). ACESSO EM: 15 JUN. 2026.

LEWIS, P. ET AL. RETRIEVAL-AUGMENTED GENERATION FOR KNOWLEDGE-INTENSIVE NLP TASKS. IN: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 33, 2020. PROCEEDINGS... NEURIPS, 2020.

MCKINSEY GLOBAL INSTITUTE. THE SOCIAL ECONOMY: UNLOCKING VALUE AND PRODUCTIVITY THROUGH SOCIAL TECHNOLOGIES. MCKINSEY & COMPANY, 2012.

NIST. ARTIFICIAL INTELLIGENCE RISK MANAGEMENT FRAMEWORK (AI RMF 1.0). GAITHERSBURG: NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY, 2023.

OPENAI. GPT-4 TECHNICAL REPORT. SAN FRANCISCO: OPENAI, 2023.

OPENAI. OPENAI API REFERENCE. SAN FRANCISCO: OPENAI, 2025. DISPONÍVEL EM: [HTTPS://PLATFORM.OPENAI.COM/DOCS](https://platform.openai.com/docs). ACESSO EM: 15 JUN. 2026.

OWASP. OWASP TOP 10 FOR LARGE LANGUAGE MODEL APPLICATIONS. THE OWASP FOUNDATION, 2023. DISPONÍVEL EM: [HTTPS://OWASP.ORG/WWW-PROJECT-TOP-10-FOR-LARGE-LANGUAGE-MODEL-APPLICATIONS/](https://owasp.org/www-project-top-10-for-large-language-model-applications/). ACESSO EM: 15 JUN. 2026.

REACT TEAM. REACT DOCUMENTATION. META OPEN SOURCE, 2025. DISPONÍVEL EM: [HTTPS://REACT.DEV](https://react.dev). ACESSO EM: 15 JUN. 2026.

RUSSELL, S.; NORVIG, P. ARTIFICIAL INTELLIGENCE: A MODERN APPROACH. 4. ED. HOBOKEN: PEARSON, 2020.

SUPABASE. SUPABASE DOCUMENTATION. SUPABASE INC., 2025. DISPONÍVEL EM: [HTTPS://SUPABASE.COM/DOCS](https://supabase.com/docs). ACESSO EM: 15 JUN. 2026.

TAILWIND LABS. TAILWIND CSS DOCUMENTATION. TAILWIND LABS, 2025. DISPONÍVEL EM: [HTTPS://TAILWINDCSS.COM/DOCS](https://tailwindcss.com/docs). ACESSO EM: 15 JUN. 2026.

TANSTACK. TANSTACK START DOCUMENTATION. TANSTACK, 2025. DISPONÍVEL EM: [HTTPS://TANSTACK.COM/START](https://tanstack.com/start). ACESSO EM: 15 JUN. 2026.

TYPESCRIPT TEAM. TYPESCRIPT HANDBOOK. MICROSOFT, 2025. DISPONÍVEL EM: [HTTPS://WWW.TYPESCRIPTLANG.ORG/DOCS/](https://www.typescriptlang.org/docs/). ACESSO EM: 15 JUN. 2026.

VASWANI, A. ET AL. ATTENTION IS ALL YOU NEED. IN: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30, 2017. PROCEEDINGS... NEURIPS, 2017.

WEI, J. ET AL. CHAIN-OF-THOUGHT PROMPTING ELICITS REASONING IN LARGE LANGUAGE MODELS. IN: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 35, 2022. PROCEEDINGS... NEURIPS, 2022.

WHITE, J. ET AL. A PROMPT PATTERN CATALOG TO ENHANCE PROMPT ENGINEERING WITH CHATGPT. ARXIV PREPRINT ARXIV:2302.11382, 2023.

YAO, S. ET AL. REACT: SYNERGIZING REASONING AND ACTING IN LANGUAGE MODELS. ARXIV PREPRINT ARXIV:2210.03629, 2022.